



Análise preditiva com IA para exercícios de musculação

Bruna França Martinez (06-J) ¹

Graziely de Oliveira Severo (06-J) ² Matheus Fernandes dos Santos (06-J) ³

Mario Olimpio de Menezes ^{1, 2}

¹Faculdade de Computação e Informática (FCI)

Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

10420225@mackenzista.com.br, 10425431@mackenzista.com.br,

10420439@mackenzista.com.br

mario.menezes@mackenzie.br

2026

Resumo

O treinamento resistido é amplamente praticado para promoção da saúde e hipertrofia, contudo a escassez de acompanhamento profissional individualizado frequentemente resulta em erros biomecânicos e lesões. Este trabalho apresenta uma proposta de análise preditiva baseada em inteligência artificial e visão computacional para o monitoramento e correção personalizada de exercícios de musculação. Utilizando o framework MediaPipe Pose para extração de coordenadas articulares a partir de registros em vídeo, desenvolve-se um modelo de regressão linear focado em quantificar desvios posturais e estimar o avanço da fadiga neuromuscular em tempo real. A base de dados experimental é constituída de forma autoral, simulando diferentes níveis de execução técnica. Espera-se como resultado um protótipo capaz de emitir alertas de risco ortopédico e orientar ajustes biomecânicos dinâmicos adaptados ao perfil do praticante.

Palavras-chave: Machine Learning; Análise Preditiva; Inteligência Artificial; Visão Computacional; Biomecânica.

Palavras-chave: Machine Learning, Análise Preditiva, Inteligência Artificial

Abstract

Resistance training is widely practiced to promote health and muscle hypertrophy; however, the lack of individualized professional supervision frequently leads to biomechanical errors and injuries. This work presents a predictive analysis proposal based on artificial intelligence and computer vision for the personalized monitoring and correction of weightlifting exercises. Utilizing the MediaPipe Pose framework to extract joint coordinates from video recordings, a linear regression model is developed to quantify postural deviations and estimate neuromuscular fatigue progression in real time. The experimental dataset is collected authorially, simulating distinct levels of technical execution. The expected outcome is a functional prototype capable of generating orthopaedic risk alerts and guiding dynamic biomechanical adjustments tailored to the practitioner's profile.

Keywords: Machine Learning; Predictive Analytics; Artificial Intelligence; Computer Vision; Biomechanics.

Keywords: Machine Learning, Predictive Analytics, Artificial Intelligence

1. Introdução

O treinamento resistido é uma das práticas de atividade física mais populares no mundo, sendo amplamente adotado por indivíduos com objetivos que vão desde a hipertrofia muscular até a prevenção de lesões, a composição corporal e a preservação da integridade musculoesquelética a longo prazo (GUO et al., 2024). Uma das partes essenciais para um estilo de vida saudável é a atividade física, neste contexto muitos indivíduos praticam treinos para melhorar seu condicionamento físico. No entanto, o monitoramento manual das atividades e a contagem humana de repetições podem ser propensas a erros; seguindo este contexto, nos últimos anos o avanço da Inteligência Artificial e do aprendizado de máquina avançaram, permitindo analisar e interpretar movimentos humanos de forma automatizada (MHAISKAR et al., 2023).

Estudos recentes demonstram que algoritmos de Machine Learning são capazes de monitorar variáveis como carga, volume, fadiga e padrões biomecânicos em tempo real durante exercícios resistidos (ALBERT; ARNRICH, 2024; BAEK et al., 2025). A predição da fadiga muscular e a estimativa do esforço percebido a partir de datasets multimodais estruturados (ALBERT et al., 2023) ilustram o alto potencial dessas tecnologias. Contudo, a aplicação de modelos preditivos voltados especificamente à análise personalizada e melhoria de execução para praticantes com diferentes perfis — do iniciante ao avançado — ainda é incipiente, configurando uma lacuna relevante na literatura.

Diante disso, este trabalho tem como objetivo geral propor um modelo de regressão linear para a análise e melhoria personalizada de exercícios resistidos, visando melhorar a

individualização do treino com diferentes perfis e níveis de condicionamento físico. Para isso, os objetivos específicos são:

- revisar a literatura sobre IA aplicada ao treinamento resistido;
- identificar as variáveis biomecânicas e de carga relevantes para a prescrição de exercícios;
- estruturar o modelo de regressão linear proposto;
- analisar a viabilidade da abordagem frente aos métodos convencionais de prescrição.

O cenário contemporâneo do treinamento de força revela uma contradição: o aumento exponencial de praticantes versus a escassez de supervisão técnica altamente qualificada em tempo real, induzindo a erros biomecânicos sistemáticos que limitam a hipertrofia e elevam o risco de lesões musculoesqueléticas (MHAISKAR et al., 2023). Sistemas de Informação modernos e redes neurais aplicadas ao esporte oferecem a infraestrutura ideal para mitigar essa lacuna, permitindo interpretar o movimento de forma automatizada e quantificar padrões de força (CAO et al., 2023). Diante disso, a hipótese desta pesquisa é que um modelo de regressão linear, alimentado por variáveis cinemáticas e antropométricas extraídas via visão computacional, é capaz de identificar desvios posturais críticos e estimar a fadiga em tempo real, gerando insights adaptativos e sugestões de correção perfeitamente calibradas ao perfil de cada usuário.

A contribuição deste trabalho está na interseção entre ciência do esporte e aprendizado de máquina, oferecendo uma solução acessível e baseada em dados para a personalização do treino resistido. O documento está organizado em sete seções: referencial teórico, metodologia, descrição do problema, aspectos éticos, descrição do dataset e resultados esperados.

Em conformidade com as diretrizes da disciplina, este projeto enquadra-se na Opção Framework, utilizando bibliotecas e ferramentas de Machine Learning e Visão Computacional (como o framework MediaPipe Pose e ecossistema Python) para extração de dados e modelagem preditiva.

2. Referencial Teórico

O referencial teórico está organizado em três eixos que convergem para o objetivo deste trabalho: os fundamentos do treinamento resistido, a aplicação de Inteligência Artificial no esporte e os modelos preditivos voltados à prescrição personalizada de exercícios.

2.1 Treinamento Resistido

O treinamento resistido promove adaptações neuromusculares e metabólicas amplamente documentadas, com benefícios que vão além da estética, incluindo preservação da massa muscular, saúde articular e longevidade (GUO et al., 2024). Sua prescrição envolve variáveis complexas como carga, volume, frequência e ângulo de trabalho muscular, cuja manipulação adequada é determinante para a eficácia e a segurança do treino (NOVATCHKOV; BACA, 2013). A ausência de individualização rigorosa e acompanhamento técnico nessa prescrição é apontada como o principal fator de risco para a ocorrência de lesões e estagnação de resultados.

2.2 Inteligência Artificial e Machine Learning no Esporte

O Machine Learning tem sido aplicado com sucesso no monitoramento de variáveis de desempenho esportivo, como controle de carga, potência gerada e mapeamento de padrões

biomecânicos (GUNERALP et al., 2025). Algoritmos de classificação e reconhecimento de movimento demonstraram viabilidade prática na análise de exercícios de força a partir do processamento digital de imagens e visão computacional (CAO et al., 2023), enquanto modelos baseados em redes neurais profundas mostraram alta acurácia na identificação e avaliação de padrões motores e atividades humanas complexas (MHAISKAR et al., 2023). Esses avanços consolidam a IA como uma ferramenta de suporte objetivo para profissionais e praticantes de atividades físicas.

2.3 Modelos Preditivos na Musculação

Estudos recentes demonstram que modelos preditivos baseados em aprendizado de máquina são plenamente capazes de estimar a fadiga muscular de forma contínua durante o treino de força (ALBERT; ARNRICH, 2024), prever o nível de desgaste mecânico por meio de algoritmos de inteligência artificial (BAEK et al., 2025) e quantificar o esforço percebido durante a execução de rotinas repetitivas (ALBERT et al., 2023).

No campo da regressão e predição aplicada à saúde postural, Bates et al. (2023) evidenciaram que intervenções de treinamento físico guiadas por sistemas inteligentes conseguem mitigar riscos clínicos, gerando melhorias expressivas na resistência física e diminuindo consideravelmente dores musculoesqueléticas crônicas, como a dor lombar.

Por outro lado, Washif et al. (2024), ao avaliarem o uso de modelos de linguagem e IA generativa na prescrição de treinos, concluíram que a ausência de dados biomecânicos individuais e em tempo real limita severamente sua eficácia e segurança técnica — o que fundamenta e justifica a proposta deste trabalho de desenvolver um modelo focado em métricas cinemáticas específicas de movimento capturadas de cada praticante.

3. Metodologia

Esta investigação classifica-se como uma pesquisa aplicada, de abordagem estritamente quantitativa e com delineamento exploratório-experimental. Caracteriza-se como aplicada por propor o desenvolvimento de um artefato tecnológico funcional direcionado à resolução de uma demanda real de saúde e performance esportiva. A abordagem é quantitativa, visto que se baseia na extração, tratamento estatístico e modelagem matemática de matrizes de coordenadas espaciais geradas pelas articulações do corpo humano. O caráter exploratório e experimental justifica-se pela manipulação controlada de variáveis biomecânicas de entrada para testar a acurácia do modelo preditivo em inferir a fadiga e a perda de eficiência técnica ao longo das repetições.

O desenvolvimento da pesquisa ocorrerá por meio de etapas sequenciais integradas. A primeira etapa consistirá no refinamento do levantamento bibliográfico e mapeamento de parâmetros técnicos para análise de movimento e aplicação de inteligência artificial na musculação (NOVATCHKOV; BACA, 2013; MHAISKAR et al., 2023). A segunda etapa compreenderá a estruturação do banco de dados e a categorização dos perfis dos usuários (iniciante, intermediário e avançado). Nesta fase, serão mapeados os limiares (thresholds) de esforço percebido e fadiga muscular a partir de datasets multimodais consolidados na literatura de treinamento resistido (ALBERT et al., 2023; BAEK et al., 2025).

A terceira etapa envolverá o planejamento experimental e a captura dos registros visuais dos exercícios em múltiplos planos, visando registrar compensações posturais sob estresse

mecânico e o monitoramento contínuo da fadiga (ALBERT; ARNRICH, 2024). Na quarta etapa, os vídeos serão processados por meio de algoritmos de visão computacional (framework MediaPipe Pose), extraindo as coordenadas das articulações e calculando os ângulos biomecânicos cruciais durante a execução.

A quinta etapa focará no desenvolvimento e treinamento do modelo de regressão linear, correlacionando os desvios cinemáticos detectados aos perfis dos usuários, herdando parâmetros analíticos aplicados na prevenção de dores musculoesqueléticas e integridade estrutural (BATES et al., 2023; GUO et al., 2024). Por fim, a sexta etapa consistirá na validação estatística e análise de acurácia das sugestões preditivas geradas pelo sistema frente às limitações das ferramentas de texto convencionais, comprovando a eficiência de um Sistema de Informação focado em dados de movimento individualizados (WASHIF et al., 2024; GUNERALP et al., 2025).

4. Descrição do Problema

A prática inadequada de exercícios de musculação e treinamento resistido representa um desafio crítico para a saúde física e para a eficiência do treinamento. Embora o acompanhamento por profissionais de educação física seja o cenário ideal, a alta proporção de praticantes por ambiente em academias resulta, frequentemente, na execução de séries sem supervisão individualizada contínua. A falta de instrução técnica imediata leva à adoção inconsciente de compensações posturais e desvios biomecânicos — como a projeção incorreta dos joelhos, o alinhamento inadequado da coluna e variações erráticas na amplitude angular articular —, fatores que elevam o risco de lesões musculoesqueléticas e reduzem o estímulo hipertrófico desejado.

Somado a isso, a fadiga neuromuscular contínua altera a cinemática do movimento ao longo das repetições. Conforme a fadiga se acumula, o praticante tende a comprometer a técnica de execução para conseguir completar o número de repetições estipulado, gerando sobrecarga em articulações e estruturas anatômicas vulneráveis. Ferramentas convencionais de prescrição ou assistentes baseados em texto não possuem capacidade analítica para interpretar métricas cinemáticas individuais e em tempo real.

Dessa forma, o problema central que este trabalho aborda é a incapacidade dos métodos tradicionais e não monitorados em quantificar e diagnosticar, em tempo real, os desvios biomecânicos e o avanço da fadiga durante a execução do exercício. A ausência de um sistema preditivo que correlacione esses dados espaciais com o perfil do usuário limita a prevenção de lesões e impede a personalização dinâmica do treino.

5. Discutir a respeito dos aspectos Éticos do uso da IA e a sua Responsabilidade no desenvolvimento da solução

O projeto pretende identificar movimentos e sugerir melhorias na execução, é necessário considerar as consequências de orientações incorretas. A ferramenta deverá servir como apoio ao acompanhamento profissional.

A utilização das gravações deverá observar as disposições aplicáveis da Lei Geral de Proteção de Dados Pessoais (LGPD), Lei nº 13.709/2018. Mesmo sendo dos próprios autores, as imagens constituem dados pessoais quando permitem sua identificação. O projeto deverá coletar apenas as

informações necessárias, restringir o acesso aos arquivos e definir os procedimentos de armazenamento e descarte, protegendo a privacidade dos participantes.

A diversidade dos dados também representa uma questão ética, pois influencia a adequação das análises para diferentes pessoas. As gravações dos autores simulando níveis de experiência não representam todas as características físicas e condições de execução dos praticantes. Essa limitação pode gerar vieses e sugestões inadequadas para perfis pouco representados na base. Por isso, os resultados deverão indicar as condições avaliadas, evitando generalizações e reconhecendo a necessidade de ampliar os testes antes de utilizar a solução com outros públicos.

A responsabilidade dos autores inclui verificar a qualidade dos dados, testar o modelo, corrigir falhas e explicar os critérios utilizados nas sugestões. As orientações deverão permitir revisão humana, mantendo a equipe responsável pelas escolhas realizadas durante o desenvolvimento. Também será necessário documentar os procedimentos, reconhecer as fontes consultadas e apresentar os resultados reais.

6. Descrição do Dataset, ou descrição detalhada do seu conteúdo/origem, análise exploratória e preparação dos dados em Python

Para a validação inicial da pipeline de pré-processamento e análise exploratória de dados (EDA), este trabalho adota temporariamente como benchmark a base de dados pública UI-PRMD (University of Idaho - Physical Rehabilitation Movement Dataset), especificamente o subconjunto referente ao exercício de Agachamento Profundo. A adoção desta base de referência justifica-se pela necessidade de homologar a arquitetura analítica enquanto a captura autoral dos dados cinemáticos dos membros do grupo está em fase de execução técnica.

O subconjunto é composto por registros de movimento de 10 indivíduos realizando repetições do exercício de agachamento em duas modalidades técnicas: execução correta (padrão biomecânico ideal) e execução incorreta (simulação de desvios posturais e compensações físicas comuns). A base disponibilizada é composta por seis arquivos CSV estruturados:

1. `Data_Correct.csv` e `Data_Incorrect.csv` (Dimensão: 10.530×240):
 - Contêm as matrizes de dados cinemáticos brutos (ângulos articulares tridimensionais) alinhados temporalmente em 240 *frames* por repetição.
 - O conjunto totaliza 90 sequências de movimento (repetições), onde cada repetição contém 117 variáveis/ângulos articulares ($90 \text{ repetições} \times 117 \text{ ângulos} = 10.530$ linhas).
2. `Autoencoder_Output_Correct.csv` e `Autoencoder_Output_Incorrect.csv` (Dimensão: 90×960):
 - Representam o espaço latente de dimensão reduzida extraído via rede neural *Autoencoder*.
 - Reduz os 117 ângulos brutos para 4 características latentes essenciais por *frame* ($4 \text{ características} \times 240 \text{ frames} = 960$ colunas por execução).
3. `Labels_Correct.csv` e `Labels_Incorrect.csv` (Dimensão: 90×1):
 - Apresentam os escores contínuos de qualidade e conformidade do movimento (*Quality Scores*), variando no intervalo $[0,1]$, calculados via Modelos de Mistura Gaussiana (*Gaussian Mixture Models - GMM*).

- Execuções corretas apresentam média de qualidade alta ($\mu = 0,944$; $\sigma = 0,011$), enquanto execuções incorretas exibem maior dispersão e menor qualidade média ($\mu = 0,860$; $\sigma = 0,067$).

7. Resultados Esperados

O desenvolvimento culminará em um protótipo funcional de software voltado à inteligência biomecânica aplicada. O sistema identificará falhas críticas como o posicionamento incorreto dos pés em relação à barra — fator que reduz o estímulo ao quadríceps e sobrecarrega a coluna (BATES et al., 2023). O software emitirá alertas instantâneos de risco ortopédico e relatórios preditivos para orientar os ajustes necessários na série seguinte, comprovando a viabilidade de sistemas autônomos na democratização do feedback de alta performance (GUNERALP et al., 2025).

8. Referências bibliográficas

ALBERT, Justin Amadeus; ARNRICH, Bert. A computer vision approach to continuously monitor fatigue during resistance training. *Biomedical Signal Processing and Control*, v. 89, p. 105701, 2024.

ALBERT, Justin Amadeus; HERDICK, Arne; BRAHMS, Clemens Markus; GRANACHER, Urs; ARNRICH, Bert. PERSIST: A Multimodal Dataset for the Prediction of Perceived Exertion during Resistance Training. *Data*, v. 8, n. 1, p. 9, 2023.

BAEK, Jun-Young; KWON, Jun-Hyeong; KHAN, Hamza; LEE, Min-Cheol. Machine Learning-Driven Muscle Fatigue Estimation in Resistance Training with Assistive Robotics. *Sensors*, v. 25, n. 21, p. 6588, 2025.

BATES, Nathaniel A. et al. Physical clinical care and artificial-intelligence-guided core resistance training improve endurance and patient-reported outcomes in subjects with lower back pain. *Clinical Biomechanics*, v. 103, p. 105902, 2023.

CAO, Xiaoxiang; ZHAO, Xiaodong; TANG, Huan; FAN, Nianchun; ZEREG, Fateh. Football players' strength training method using image processing based on machine learning. *PLoS ONE*, v. 18, n. 6, p. e0287433, 2023.

COPPIN, B. Inteligência artificial. Rio de Janeiro: LTC, 2010.

GUNERALP, Huseyin; YAVUZ, Hasan Ulas; SEKEROGLU, Boran; OYTUN, Musa; TINAZCI, Cevdet. Analysis of Combined Strength Training with Small-Sided Games in Football Education Using Machine Learning Methods. *Applied Sciences*, v. 15, n. 10, p. 5672, 2025.

GUO, Hongzhi et al. Quantifying the Enhancement of Sarcopenic Skeletal Muscle Preservation Through a Hybrid Exercise Program: Randomized Controlled Trial. *JMIR Aging*, v. 7, p. e58175, 2024.

INTEL CORPORATION. Intel RealSense Depth Camera D435i. Intel Corporation, 2020. Disponível em: <https://www.intelrealsense.com/depth-camera-d435i>. Acesso em: 07 de abril de 2024.

MHAISKAR, Rutuja et al. Performance Analysis of Human Activity. *ITM Web of Conferences*, [S. l.], v. 56, n. 05006, 2023. Disponível em: <https://doi.org/10.1051/itmconf/20235605006>. Acesso em: 22 maio 2024..

NOVATCHKOV, Hristo; BACA, Arnold. Artificial Intelligence in Sports on the Example of Weight Training. *Journal of Sports Science and Medicine*, v. 12, p. 27-37, 2013.

RUSSELL, S.; NORVIG, P. Inteligência artificial. Rio de Janeiro: LTC, 2021.

SZELISKI, R. Computer Vision: Algorithms and Applications. New York: Springer, 2021.

UNIVERSIDADE PRESBITERIANA MACKENZIE. Guia do TCC: Orientações gerais para a elaboração do trabalho de conclusão dos cursos de graduação. São Paulo: UPM, 2021.

VAKANSKI, A. et al. A Deep Learning Framework for Assessing Physical Rehabilitation Exercises: UI-PRMD dataset. GitHub, 2020. Disponível em: <https://github.com/avakanski/A-Deep-Learning-Framework-for-Assessing-Physical-Rehabilitation-Exercises>. Acesso em: 14 set. 2026.



VAKANSKI, A. et al. A data-driven framework for assessing physical rehabilitation exercises. IEEE Transactions on Neural Systems and Rehabilitation Engineering, v. 28, n. 4, p. 888-898, 2020. Disponível em: <https://doi.org/10.1109/TNSRE.2020.2977273>. Acesso em: 14 set. 2026.

WASHIF, Jad Adrian et al. ChatGPT and exercise prescription: Artificial intelligence in sport: Exploring the potential of using ChatGPT in resistance training prescription. Biology of Sport, v. 41, n. 2, p. 209-220, 2024.